Progetto di sperimentazione di prompt engineering

su dataset MACID (text-only)

Miriam Magazzini

16/07/2026

1 Introduzione e Descrizione del Dataset

Il progetto si inserisce nel contesto della valutazione delle capacità di comprensione linguistica dei Large Language Models (LLM) in lingua italiana.

Il dataset MACID è progettato per testare la capacità dei modelli di risolvere sottili ambiguità linguistiche legate alla descrizione di azioni. Ispirato al gioco del "trova l'intruso", il dataset richiede al modello di analizzare un set di frasi (descrizioni testuali di eventi visivi o azioni fisiche, come ad esempio vari tipi di "spinta") e di identificare l'azione intrusa. Questa sfida è particolarmente complessa perché si concentra sui disallineamenti tra azione e predicato: a volte lo stesso verbo descrive azioni visivamente diverse, e a volte verbi diversi si riferiscono alla stessa azione. Sebbene il dataset nasca come risorsa multimodale (testo e video), questo progetto si concentra esclusivamente sulla modalità *text-only*.

2 Scopo del Progetto

L'obiettivo principale di questo lavoro è dimostrare come l'applicazione di tecniche avanzate di Prompt Engineering (come *Few-Shot Prompting*, *Chain-of-Thought*, ecc.) possa colmare il divario prestazionale tra modelli linguistici di dimensioni contenute e modelli massivi che richiedono enormi risorse di calcolo.

Nello specifico, l'esperimento mira a testare modelli di taglia "piccola" (tra i 7B e i 9B di parametri, eccezione Phi-4 di 14B) in un ambiente locale con risorse limitate (16 GB di RAM tramite l'infrastruttura Ollama), sfruttando l'efficienza della quantizzazione. Lo scopo è ottimizzare il prompt e il ragionamento logico del modello per raggiungere o superare le performance ottenute in letteratura da modelli molto più grandi e pesanti, dimostrando che un "prompting intelligente" può sostituire la "forza bruta" dei parametri hardware.

3 Stato dell'Arte e Risultati da Battere (Baseline)

I risultati di riferimento (*baseline*) per questo progetto sono tratti dalla recente iniziativa della comunità italiana di linguistica computazionale, documentati nell'articolo

"Challenging the Abilities of Large Language Models in Italian: a Community Initiative" (arXiv:2512.04759).

Tabella 1: Baseline di Accuratezza sul dataset MACID (text-only)

Modello	**Accuratezza**
MINERVA-7B	0.27
LLAMA 3.1-8B	0.43
ANITA-8B	0.43
LLAMA 3.1-70B	**0.58**

L'obiettivo di superamento è la soglia dello **0.58 (58%)**, ottenuto dal modello Llama 3.1 da 70B.

4 Metodologia e Architettura dei Prompt

Il progetto implementa una pipeline di Prompt Engineering strutturata.

4.1 Role Prompting

Per affrontare le sottigliezze semantiche del dataset MACID, il prompt inizia assegnando un'identità specifica: *"Agisci come un esperto linguista e analista semantico, specializzato nel riconoscere le sfumature e le ambiguità delle azioni descritte in lingua italiana."* Questa tecnica restringe lo spazio vettoriale del modello.

4.2 Few-Shot Prompting

È stata implementata la tecnica del Few-Shot, inserendo nel contesto iniziale del modello K esempi creati ad hoc. Ogni esempio mostra al modello la struttura precisa: le frasi di input, il processo di ragionamento e l'output atteso, fungendo da guida per il *pattern recognition*.

4.3 Zero-Shot Chain-of-Thought (CoT)

Questa è la tecnica cardine dell'esperimento. Il prompt costringe il modello a esplicitare i passaggi logici intermedi prima di fornire l'etichetta finale, utilizzando la direttiva: *"Analizza le frasi passo dopo passo (Let's think step by step)."* Così facendo, il modello aumenta le probabilità che la risposta finale sia semanticamente corretta.

4.4 Vincoli di Formato tramite Tag XML

Per rendere automatica e deterministica la valutazione, il modello è stato istruito a separare l'eventuale ragionamento dalla risposta finale, racchiudendo quest'ultima in un tag XML personalizzato: *"Restituisci l'ID della frase intrusa esclusivamente all'interno del tag ¡risposta¿...¡/risposta¿."* In questo modo l'algoritmo di validazione può estrarre la classe predetta tramite un'espressione regolare, senza ambiguità. L'espediente si rivela particolarmente utile nella strategia Chain-of-Thought, dove il modello cita più numeri

nel corso del ragionamento (ad esempio *"le frasi 1, 2 e 4 sono simili, dunque la risposta è 3"*): l'estrazione basata sull'ultimo numero presente nel testo, usata come fallback, individua la risposta corretta solo se questa compare per ultima, condizione non sempre garantita.

5 Implementazione: lo script `evaluate_macid.py`

Questa sezione descrive nel dettaglio lo script Python che implementa la pipeline sperimentale, spiegando passo per passo le scelte implementative.

5.1 Infrastruttura di esecuzione

Lo script è stato progettato per eseguire i modelli localmente tramite **Ollama**. La comunicazione tra lo script Python e il server Ollama avviene tramite la libreria `ollama` ufficiale, che espone una funzione `ollama.chat()` analoga nell'interfaccia alle API REST dei principali provider commerciali.

Questa scelta architetturale ha permesso di eseguire l'intera sperimentazione anche su hardware privo di GPU dedicata, oltre che su un'istanza GPU gratuita di Google Colab nei casi in cui i tempi di esecuzione su CPU risultassero proibitivi.

5.2 Struttura dei dati

Il dataset MACID (100 quadruple di frasi) viene caricato da un file `macid_data.csv`, con una riga per quadrupla e colonne `s1--s4` (le quattro frasi) e `intruder` (l'indice, da 1 a 4, della frase intrusa secondo l'annotazione originale).

5.3 Catalogo dei modelli e delle strategie

Lo script organizza modelli e strategie come due *cataloghi* centralizzati, definiti in cima al file:

- `MODELLI_DISPONIBILI`: lista dei nomi dei modelli Ollama utilizzabili (es. `"llama3.1:8b"`, `"mistral"`, `"qwen2.5:7b"`, `"gemma2:9b"`, `"phi4"`);
- `STRATEGIE_BASE`: dizionario che associa ciascuna delle quattro strategie principali (Zero-Shot, Zero-Shot+Role, Few-Shot, Chain-of-Thought) alla rispettiva funzione Python di costruzione del prompt;
- `STRATEGIE_DISPONIBILI`: estende il catalogo base con strategie di follow-up, in particolare la combinazione Few-Shot+Chain-of-Thought (Sezione 5.5).

5.4 Costruzione dei prompt

Per ciascuna strategia è definita una funzione dedicata (`build_prompt_*`) che riceve in input una riga del dataset e restituisce la stringa di prompt completa da inviare al modello.

Zero-Shot. La funzione `build_prompt_zeroshot` costruisce un prompt deliberatamente *privo* di Role Prompting e di vincoli di formato XML. Questa scelta implementativa garantisce che il confronto fra i modelli testati e la baseline avvenga a parità di condizioni sperimentali.

Zero-Shot+Role. La funzione `build_prompt_zeroshot_role` introduce una condizione sperimentale pensata per isolare il contributo del solo Role Prompting. Il prompt riprende la stessa domanda dello Zero-Shot puro, ma vi antepone la stringa di Role Prompting e ne vincola l'output al formato XML `<risposta>N</risposta>`. La motivazione di questa scelta implementativa è metodologica: nelle altre tre strategie "potenziate" (Few-Shot, Chain-of-Thought, Few-Shot+CoT) il Role Prompting compare sempre congiuntamente ad altri elementi (esempi pre-risolti, istruzione di ragionamento esplicito), rendendo impossibile, a partire dal solo confronto con lo Zero-Shot puro, stabilire quale di questi elementi sia effettivamente responsabile di un eventuale miglioramento prestazionale. Confrontando Zero-Shot e Zero-Shot+Role a parità di ogni altra condizione è invece possibile attribuire l'eventuale differenza di accuratezza al solo effetto dell'assegnazione di un ruolo esperto al modello.

Few-Shot, Chain-of-Thought e Few-Shot+CoT. Le restanti tre funzioni di costruzione del prompt condividono, insieme alla strategia Zero-Shot+Role appena descritta, due componenti testuali predefinite come costanti globali:

- `RUOLO`: la stringa di Role Prompting (*"Agisci come un esperto linguista e analista semantico..."*);
- `ISTRUZIONE_FORMATO_XML`: l'istruzione che vincola il modello a restituire l'ID della frase intrusa esclusivamente dentro il tag `<risposta>...</risposta>`.

Il prompt Chain-of-Thought aggiunge inoltre l'istruzione esplicita *"Analizza le frasi passo dopo passo (Let's think step by step)"*, mentre il prompt Few-Shot include tre esempi pre-risolti (costante `FEWSHOT_EXAMPLES_XML`), ciascuno composto da quattro frasi, una breve spiegazione del criterio di scelta dell'intruso, e la risposta nel medesimo formato XML richiesto al modello in fase di test. La strategia combinata Few-Shot+CoT (`build_prompt_fewshot_cot`) riunisce entrambi gli elementi: esempi pre-risolti e istruzione di ragionamento esplicito.

5.5 Testo integrale dei prompt

Di seguito è riportato il testo effettivo di ciascun prompt inviato ai modelli. Le quattro frasi della quadrupla in esame sono indicate con i segnaposto `[frase 1]`-`[frase 4]`; nel prompt reale vengono sostituite dalle frasi corrispondenti. Le due componenti testuali condivise dalle strategie potenziate sono la stringa di ruolo (costante `RUOLO`) e l'istruzione di formato (costante `ISTRUZIONE_FORMATO_XML`):

```
RUOLO: Agisci come un esperto linguista e analista semantico, specializzato
nel riconoscere le sfumature e le ambiguità delle azioni descritte in
lingua italiana.

ISTRUZIONE_FORMATO_XML: Restituisci l'ID della frase intrusa esclusivamente
all'interno del tag <risposta>...</risposta>, ad esempio
<risposta>3</risposta>.
```

Zero-Shot.

```
Le seguenti 4 frasi sono descrizioni di azioni fisiche.  Tre di queste
azioni sono dello stesso tipo, mentre una è di un tipo diverso.  Individua
```

la frase che descrive l'azione di tipo diverso rispondendo soltanto con il numero della frase (1, 2, 3 o 4).

1: [frase 1]
2: [frase 2]
3: [frase 3]
4: [frase 4]

Zero-Shot+Role.

[RUOLO]

Le seguenti 4 frasi sono descrizioni di azioni fisiche. Tre di queste azioni sono dello stesso tipo, mentre una è di un tipo diverso. Individua la frase che descrive l'azione di tipo diverso.

1: [frase 1]
2: [frase 2]
3: [frase 3]
4: [frase 4]

[ISTRUZIONE_FORMATO_XML]

Few-Shot.

[RUOLO]

Le seguenti 4 frasi sono descrizioni di azioni fisiche. Tre di queste azioni sono dello stesso tipo, mentre una è di un tipo diverso. Ti mostro alcuni esempi già risolti, poi ti chiedo di risolvere un nuovo caso nello stesso modo.

[ISTRUZIONE_FORMATO_XML]

Esempio 1:
1: L'uomo preme il pulsante dell'ascensore
2: La donna preme il tasto del telecomando
3: Il ragazzo spinge il carrello lungo il corridoio
4: Il soldato preme il grilletto della pistola
(le frasi 1, 2 e 4 descrivono tutte un'azione di ''premere'' qualcosa con un dito, mentre la 3 descrive un'azione di ''spingere'' con tutto il corpo)
<risposta>3</risposta>

Esempio 2:
1: La donna spinge la sedia a rotelle
2: L'infermiere spinge la barella
3: Il ragazzo preme il pulsante di accensione
4: Il facchino spinge il carrello dei bagagli
(le frasi 1, 2 e 4 descrivono tutte un'azione di ''spingere'' un oggetto con ruote per farlo muovere, mentre la 3 descrive un'azione di ''premere'' un pulsante)
<risposta>3</risposta>

Esempio 3:
1: Il ragazzo si solleva sulle braccia per alzarsi
2: L'uomo si tira su in ginocchio
3: La donna spinge il carrello della spesa
4: Il soldato si spinge sulle braccia per mettersi in ginocchio
(le frasi 1, 2 e 4 descrivono tutte un movimento del corpo per rialzarsi, mentre la 3 descrive lo spostamento di un oggetto)
<risposta>3</risposta>

Ora risolvi questo caso:

```
1:  [frase 1]
2:  [frase 2]
3:  [frase 3]
4:  [frase 4]
```

Chain-of-Thought.

```
[RUOLO]

Le seguenti 4 frasi sono descrizioni di azioni fisiche.  Tre di queste
azioni sono dello stesso tipo, mentre una è di un tipo diverso.

1:  [frase 1]
2:  [frase 2]
3:  [frase 3]
4:  [frase 4]

Analizza le frasi passo dopo passo (Let's think step by step):  qual è il
tipo di azione condiviso da tre delle frasi?  Quale frase non rientra in
quel tipo di azione, anche se può usare un verbo simile?

[ISTRUZIONE_FORMATO_XML]
```

Few-Shot+CoT. Riprende gli stessi tre esempi della strategia Few-Shot, cambiando l'introduzione (che annuncia la presenza del ragionamento) e la richiesta finale, in cui si domanda esplicitamente di ragionare passo dopo passo prima di fornire la risposta:

```
[RUOLO]

Le seguenti 4 frasi sono descrizioni di azioni fisiche.  Tre di queste
azioni sono dello stesso tipo, mentre una è di un tipo diverso.  Ti mostro
alcuni esempi già risolti con il loro ragionamento, poi ti chiedo di
risolvere un nuovo caso nello stesso modo.

[ISTRUZIONE_FORMATO_XML]

[i medesimi tre esempi della strategia Few-Shot]

Ora risolvi questo caso.  Analizza le frasi passo dopo passo (Let's think
step by step), poi dai la risposta finale.

1:  [frase 1]
2:  [frase 2]
3:  [frase 3]
4:  [frase 4]
```

Riformulazioni per il test di robustezza (`role-v2` e `role-v3`). Le due varianti mantengono identico il contenuto informativo dello Zero-Shot+Role (stesso ruolo, stesso compito, stesso vincolo di output) e ne modificano solo la formulazione. Nella variante 2 il ruolo è espresso in forma più assertiva:

```
Sei un linguista esperto di semantica delle azioni.  Il tuo compito è
distinguere con precisione i diversi tipi di azione fisica descritti in
lingua italiana.

Qui sotto trovi quattro frasi, ciascuna descrive un'azione fisica.  Tre
descrivono lo stesso tipo di azione; una descrive un tipo di azione
differente.  Trova quella diversa dalle altre.

1:  [frase 1]
2:  [frase 2]
3:  [frase 3]
4:  [frase 4]
```

```
Fornisci il numero della frase diversa unicamente dentro il tag
<risposta>...</risposta>, per esempio <risposta>3</risposta>.
```

Nella variante 3 il ruolo è invece espresso in forma più neutra:

```
In qualità di analista del linguaggio, valuta con attenzione le seguenti
descrizioni di azioni.

Tra le quattro frasi seguenti, tutte relative ad azioni fisiche, tre
appartengono alla stessa categoria di azione e una a una categoria diversa.
Identifica la frase che non appartiene alla stessa categoria delle altre
tre.

1:  [frase 1]
2:  [frase 2]
3:  [frase 3]
4:  [frase 4]

Indica il numero corrispondente alla frase estranea soltanto all'interno
del tag <risposta>...</risposta>, come in <risposta>3</risposta>.
```

5.6 Estrazione della risposta dal testo generato

La funzione `estrai_numero` converte il testo grezzo restituito dal modello in un'etichetta numerica (1-4) interpretabile dal sistema di valutazione, secondo una logica a due livelli:

1. Viene innanzitutto cercato il pattern `<risposta>N</risposta>` (con tolleranza per maiuscole/minuscole e spazi interni al tag). Se presente, il numero contenuto nel tag è restituito direttamente come risposta del modello;

2. Se il tag XML non è presente nel testo (caso atteso per la strategia Zero-Shot, che non lo richiede, oppure caso di un modello che non ha rispettato l'istruzione di formato) la funzione ricade sul comportamento di estrazione testuale: viene cercato l'*ultimo* numero compreso tra 1 e 4 presente nel testo della risposta.

5.7 Esecuzione delle chiamate al modello

La funzione `chiedi_al_modello` invia il prompt al modello tramite `ollama.chat()`, con un meccanismo di *retry* automatico (fino a due tentativi) in caso di errore transitorio, ad esempio dovuto al tempo di caricamento del modello in memoria al primo utilizzo. La temperatura di campionamento è fissata a 0 per tutte le valutazioni, così da garantire output deterministici e pienamente riproducibili: il valore viene impostato esplicitamente nella chiamata a `ollama.chat()`, poiché in caso contrario Ollama adotterebbe una temperatura di default superiore a zero.

5.8 Riformulazioni per il test di robustezza del prompt

Per valutare quanto le prestazioni dipendano non solo dalla tecnica di prompting scelta, ma anche dalla formulazione linguistica specifica con cui la tecnica è realizzata, lo script include due riformulazioni della strategia `zero-shot+role`, registrate come `role-v2` e `role-v3`. Le tre versioni, la formulazione originale (`zero-shot+role`) e le due varianti, veicolano un contenuto informativo identico: la stessa identità assegnata al modello (un esperto linguista e analista semantico), la stessa descrizione del compito e lo stesso vincolo di output all'interno del tag `<risposta>N</risposta>`. Ciò che cambia fra una versione

e l'altra è esclusivamente il *wording*: la scelta delle parole, il registro con cui è espresso il ruolo (più assertivo nella variante 2, più neutro nella variante 3) e l'ordine con cui l'informazione è presentata.

5.9 Output prodotti

Al termine dell'esecuzione, lo script produce:

- `risultati_macid.csv`: il risultato grezzo di ciascuna combinazione (quadrupla, modello, strategia), comprensivo della risposta testuale integrale restituita dal modello;
- `riepilogo_accuratezza.csv`: l'accuratezza aggregata per ciascuna combinazione modello/strategia, calcolata e stampata a schermo dalla funzione `riassunto`.

Questi due file costituiscono l'input della fase di analisi successiva (script `analyze_results.py`), descritta nella sezione seguente.

6 Risultati

6.1 Modelli testati

La sperimentazione ha coinvolto cinque modelli open-weight, eseguiti localmente tramite l'infrastruttura Ollama. Quattro di essi appartengono alla fascia di dimensioni contenute (7–9 miliardi di parametri), in linea con i modelli usati come baseline nel paper CALAMITA; a questi si aggiunge Phi-4, di taglia superiore (circa 14 miliardi di parametri), incluso come termine di confronto per valutare l'effetto della dimensione del modello sul task:

- **LLaMA 3.1 8B** (Meta), stessa famiglia e dimensione del modello LLaMA 3.1-8B usato come baseline nel paper CALAMITA, scelto per garantire un confronto di continuità diretta;
- **Mistral 7B** (Mistral AI);
- **Qwen 2.5 7B** (Alibaba), con training multilingue particolarmente esteso;
- **Gemma 2 9B** (Google);
- **Phi-4 14B** (Microsoft).

6.2 Accuratezza per modello e strategia

La Tabella 2 riporta l'accuratezza ottenuta da ciascun modello sulle quattro strategie base (Zero-Shot, Zero-Shot+Role, Few-Shot, Chain-of-Thought), confrontata con la baseline CALAMITA.

Il quadro complessivo mostra una forte variabilità fra i modelli: la migliore accuratezza di ciascun modello va dallo 0.44 di LLaMA 3.1 8B fino allo 0.65 di Phi-4, con una separazione fra i tre modelli di testa (Phi-4, Gemma 2 9B e Qwen 2.5 7B) e gli altri due. **Phi-4** è risultato il modello più accurato in assoluto: supera la soglia di 0.58 ottenuta da LLaMA 3.1-70B nel paper CALAMITA su *tutte* le strategie, con un picco di 0.65 sulla Few-Shot. Si tratta però di un modello da circa 14 miliardi di parametri, e il confronto

Tabella 2: Accuratezza dei modelli testati sul task MACID, per strategia.

Modello	**Zero-Shot**	**Zero-Shot+Role**	**Few-Shot**	**Chain-of-Thought**
LLaMA 3.1 8B	0.44	0.40	0.09*	0.39
Mistral 7B	0.30	0.45	0.29	0.42
Qwen 2.5 7B	0.50	0.56	0.55	0.48
Gemma 2 9B	0.56	0.60	0.60	0.49
Phi-4 (14B)	0.62	0.62	0.65	0.60
Baseline CALAMITA (Zero-Shot, riferimento)				
LLaMA 3.1-70B	0.58	–	–	–
LLaMA 3.1-8B	0.43	–	–	–
Anita-8B	0.43	–	–	–
Minerva-7B	0.27	–	–	–

*Il valore anomalo di LLaMA 3.1 8B sulla strategia Few-Shot è dovuto a un fenomeno di rifiuto sistematico del modello, non a un errore di classificazione: si veda la discussione dedicata in Sezione 7.3.

con la baseline da 70B va quindi letto tenendo conto del fatto che si tratta comunque di un modello sensibilmente più grande degli altri quattro testati. Anche **Gemma 2 9B** supera la baseline da 70B con le strategie Role Prompting e Few-Shot (entrambe 0.60), pur restando un modello di taglia contenuta, mentre **Qwen 2.5 7B** si ferma poco sotto (0.56 con il Role Prompting) restando comunque ampiamente al di sopra della baseline CALAMITA per i modelli della sua taglia (0.43). Come si vedrà nella sottosezione successiva, le differenze fra questi tre modelli di testa non risultano statisticamente significative.

Il dato più interessante sul piano del prompting engineering riguarda però il *diverso* modo in cui i modelli rispondono alle tecniche potenziate. Rispetto allo Zero-Shot puro, l'aggiunta del solo Role Prompting migliora l'accuratezza di tre modelli su cinque (Mistral, Qwen 2.5 7B e Gemma 2 9B), resta sostanzialmente neutra per Phi-4 (0.62 in entrambe le configurazioni) e produce un lieve calo solo su LLaMA 3.1 8B (da 0.44 a 0.40). L'effetto è particolarmente marcato su **Mistral 7B**, il cui Zero-Shot puro (0.30) è appena al di sopra del caso casuale (0.25) e nettamente al di sotto della baseline CALAMITA a parità di taglia, ma che con il Role Prompting sale a 0.45 (+0.15) e con il Chain-of-Thought a 0.42 (+0.12): è il modello che trae il massimo beneficio dal prompting strutturato.

La strategia Few-Shot mostra invece un comportamento bimodale — è la migliore in assoluto per Phi-4 (0.65) e fra le migliori per Gemma 2 9B (0.60) e Qwen 2.5 7B (0.55), ma non porta alcun vantaggio a Mistral (0.29) e provoca il crollo di LLaMA 3.1 8B (0.09) per via del rifiuto sistematico discusso in Sezione 7.3.

Il Chain-of-Thought, infine, non risulta la strategia migliore per nessuno dei cinque modelli: si colloca al di sotto dello Zero-Shot puro per i tre modelli più accurati (Qwen, Gemma, Phi-4) e produce un miglioramento solo su Mistral, mentre anche su LLaMA il CoT è leggermente peggiore dello Zero-Shot puro (come sui tre modelli di testa). Nel complesso, questi risultati suggeriscono che l'efficacia di una data tecnica di prompting non sia una proprietà del task in sé, ma dipenda in misura marcata dal singolo modello a cui viene applicata.

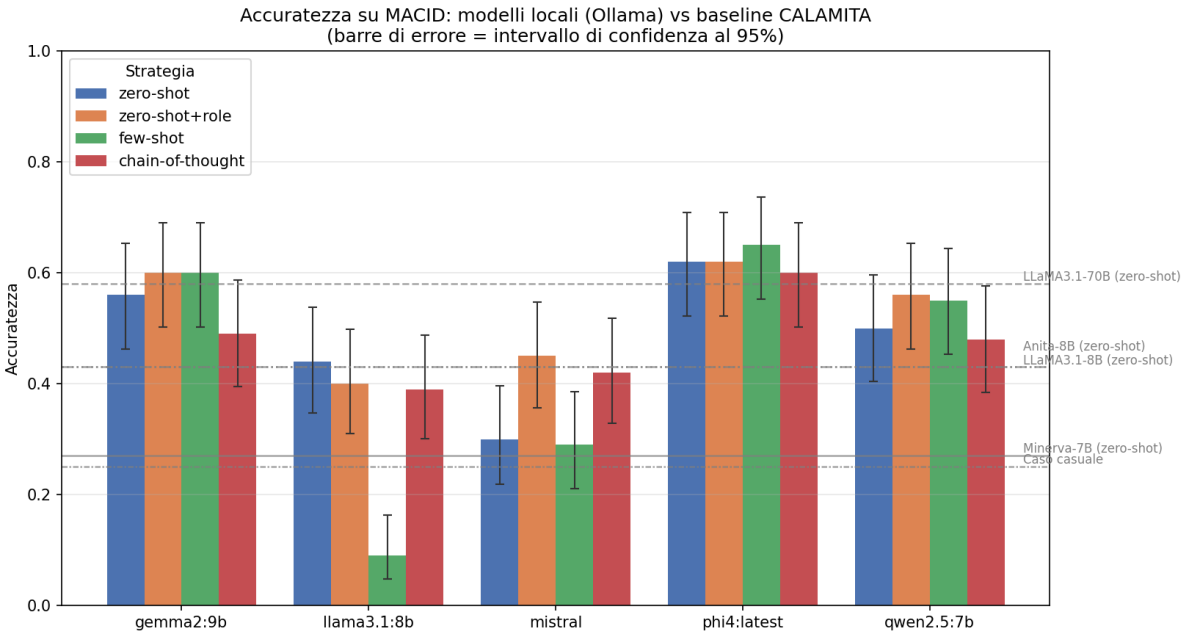


Figura 1: Accuratezza sul task MACID dei cinque modelli open-weight testati, per ciascuna strategia di prompting, a confronto con le baseline zero-shot del benchmark CALAMITA (linee orizzontali grigie). Le barre di errore rappresentano l'intervallo di confidenza al 95% calcolato con il metodo di Wilson: dove gli intervalli di due barre si sovrappongono ampiamente, la differenza osservata potrebbe non essere statisticamente significativa (si vedano i test di McNemar nella sezione seguente).

6.3 Intervalli di confidenza e significatività statistica

Data la dimensione contenuta del dataset di test (100 quadruple), è opportuno accompagnare ogni stima di accuratezza con il relativo intervallo di confidenza, e verificare se le differenze osservate tra condizioni sperimentali siano statisticamente significative o plausibilmente dovute al caso.

Per ciascuna combinazione modello/strategia è stato calcolato l'intervallo di confidenza al 95% tramite il metodo di Wilson. I risultati completi sono riportati in Tabella 3.

Tabella 3: Accuratezza con intervallo di confidenza al 95% (Wilson) per Phi-4, il modello con le prestazioni migliori.

Strategia	**Accuratezza**	**IC 95% inf.**	**IC 95% sup.**
Zero-Shot	0.62	0.52	0.71
Zero-Shot+Role	0.62	0.52	0.71
Few-Shot	0.65	0.55	0.74
Chain-of-Thought	0.60	0.50	0.69

Per verificare se le differenze di accuratezza tra modelli (a parità di strategia) e tra strategie (a parità di modello) siano statisticamente significative, è stato applicato il test di McNemar, appropriato quando le stesse unità sperimentali (le 100 quadruple) vengono valutate sotto due condizioni diverse. Il test confronta i soli casi in cui le due condizioni sono in disaccordo, stimando la probabilità che tale disaccordo sia dovuto al caso.

Per quanto riguarda i confronti *fra modelli* (a parità di strategia), il test conferma la separazione fra il gruppo di testa e quello di coda, ma non distingue i modelli all'interno del gruppo di testa. Sia Phi-4 sia Gemma 2 9B risultano significativamente più accurati di Mistral 7B e di LLaMA 3.1 8B sulle strategie Zero-Shot e Few-Shot (ad esempio, sullo Zero-Shot, Phi-4 vs Mistral $p < 0.0001$ e Gemma vs LLaMA $p = 0.031$). Al contrario, le differenze fra i tre modelli migliori (Phi-4, Gemma 2 9B e Qwen 2.5 7B) *non* raggiungono la significatività: il confronto diretto fra Phi-4 e Gemma, in particolare, dà $p = 0.38$ sullo Zero-Shot, $p = 0.83$ sullo Zero-Shot+Role e $p = 0.42$ sul Few-Shot. In altre parole, pur avendo Phi-4 l'accuratezza numerica più alta, i dati a disposizione non consentono di affermare che sia realmente superiore a Gemma 2 9B o a Qwen 2.5 7B su questo task: la differenza osservata rientra nella variabilità campionaria attesa con 100 quadruple.

Per i confronti *fra strategie* (a parità di modello), il quadro è coerente con quanto osservato sulle accuratezze grezze. Per i due modelli più forti, Phi-4 e Qwen 2.5 7B, *nessuna* coppia di strategie mostra una differenza significativa (tutti i $p > 0.09$): per questi modelli il prompting strutturato non produce un effetto statisticamente rilevabile rispetto allo Zero-Shot puro. L'effetto del prompting emerge invece con chiarezza sui modelli più deboli: per Mistral 7B il Role Prompting è significativamente superiore sia allo Zero-Shot ($0.30 \rightarrow 0.45$, $p = 0.0026$) sia al Few-Shot ($p = 0.027$), confermando che l'identità assegnata al modello ne rovescia sostanzialmente le prestazioni; per Gemma 2 9B il Chain-of-Thought risulta significativamente peggiore sia del Few-Shot ($p = 0.046$) sia del Role Prompting ($p = 0.0074$); per LLaMA 3.1 8B, infine, il crollo del Few-Shot è significativo rispetto a tutte le altre strategie ($p < 0.0001$), come atteso dato il fenomeno di rifiuto.

6.4 Strategia combinata Few-Shot + Chain-of-Thought

A seguito dei risultati ottenuti con le quattro strategie base, è stata condotta una sperimentazione aggiuntiva e mirata sui due modelli con l'accuratezza media più elevata, applicando una strategia che combina gli esempi risolti del Few-Shot con la richiesta di ragionamento esplicito del Chain-of-Thought.

Tabella 4: Confronto tra la strategia combinata Few-Shot+CoT e la migliore tra le quattro strategie base, per i due modelli selezionati.

Modello	**Migliore strategia base**	**Few-Shot+CoT**	**Differenza**
Phi-4	0.65 (Few-Shot)	0.62	−0.03
Gemma 2 9B	0.60 (Few-Shot)	0.53	−0.07

Su entrambi i modelli selezionati la strategia combinata si è collocata al di sotto della rispettiva migliore strategia base.

Per Phi-4 il Few-Shot+CoT ha raggiunto 0.62, tre punti sotto il suo Few-Shot puro (0.65); per Gemma 2 9B ha raggiunto 0.53, sette punti sotto il suo Few-Shot (0.60). In nessuno dei due casi il calo è statisticamente significativo al test di McNemar (Phi-4 $p = 0.65$, Gemma $p = 0.14$), per cui non se ne può concludere un reale effetto di peggioramento; resta però il dato, coerente tra i due modelli, che l'unione di esempi risolti e ragionamento esplicito non ha prodotto alcun guadagno rispetto alle strategie da cui deriva, anzi si è collocata leggermente al di sotto di entrambe. Il risultato è in linea

con quanto osservato sulle strategie base, dove il Chain-of-Thought tendeva a penalizzare i modelli più accurati.

6.5 Sensibilità alla formulazione del prompt

Le analisi precedenti confrontano *tecniche* di prompting diverse. Un esperimento aggiuntivo ha inteso invece isolare un fattore più sottile: a parità di tecnica, quanto incide la specifica *formulazione linguistica* con cui il prompt è scritto?

L'esperimento è stato condotto su Mistral 7B, il modello che nelle strategie base si era mostrato più sensibile al prompting (si veda l'ampio guadagno del Role Prompting rispetto allo Zero-Shot puro), e a temperatura 0, così da attribuire ogni differenza osservata unicamente al wording e non alla variabilità di campionamento.

Tabella 5: Accuratezza di Mistral 7B su tre formulazioni della stessa strategia Zero-Shot+Role, a contenuto informativo identico e wording diverso. Intervallo di confidenza al 95% (Wilson).

Formulazione	**Accuratezza**	**IC 95% inf.**	**IC 95% sup.**
Originale (Zero-Shot+Role)	0.45	0.36	0.55
Variante 2 (assertiva)	0.41	0.32	0.51
Variante 3 (neutra)	0.26	0.18	0.35

I risultati, riportati nella Tabella 5, mostrano un'oscillazione notevole: l'accuratezza varia da 0.45 della formulazione originale a 0.26 della variante neutra, uno scarto di 19 punti percentuali ottenuto senza modificare in alcun modo il contenuto della richiesta. La sola riformulazione neutra (variante 3) fa collassare le prestazioni al livello del caso (0.26 contro il 0.25 atteso da una scelta casuale). Il test di McNemar conferma che questo calo non è imputabile al rumore campionario: la variante 3 è significativamente peggiore sia della formulazione originale ($p = 0.004$) sia della variante assertiva ($p = 0.015$), mentre la differenza fra la formulazione originale e la variante 2 non è significativa ($p = 0.42$).

Questo risultato rafforza, dall'interno di una singola strategia, la tesi che attraversa l'intero lavoro: l'efficacia di un prompt non dipende solo dalla tecnica adottata, ma anche dalla sua realizzazione linguistica puntuale.

7 Analisi degli Errori

7.1 Effetto della sovrapposizione lessicale (verbo condiviso)

E' stato verificato se l'accuratezza dei modelli vari in funzione del fatto che la frase intrusa *condivida o meno il verbo principale* con almeno una delle altre tre frasi del gruppo.

Tabella 6: Accuratezza di Phi-4, strategia Few-Shot, in funzione della condivisione del verbo tra intruso e altre frasi del gruppo.

Condizione	**Accuratezza**	**N. casi**
Verbo NON condiviso (caso più semplice)	0.84	32
Verbo condiviso (caso più ambiguo)	0.51	61

I 7 casi in cui l'euristica non riesce a determinare il verbo principale dell'intruso (perché non rientra nel piccolo insieme di radici verbali tracciate) sono stati esclusi dal confronto anziché essere conteggiati impropriamente come "verbo non condiviso"; su di essi Phi-4 raggiunge comunque un'accuratezza molto alta (7 su 7 corretti con la strategia Few-Shot), coerentemente con il fatto che si tratta perlopiù di intrusi lessicalmente ben distinti.

Il risultato è netto e conferma l'ipotesi di partenza: l'accuratezza è molto più bassa nei casi in cui l'intruso condivide il verbo principale con almeno un'altra frase del gruppo (0.51) rispetto ai casi in cui il verbo è distinto (0.84). Il modello si affida in misura non trascurabile a un confronto lessicale superficiale: quando l'intruso è isolabile già dal verbo, il compito diventa quasi banale, mentre quando tutte e quattro le frasi ruotano attorno allo stesso verbo (tipicamente "spingere" o "premere") e la differenza è puramente semantica, le prestazioni si avvicinano al livello del caso. Lo stesso andamento si osserva, con divari analoghi, su tutti e cinque i modelli testati e su tutte le strategie.

7.2 Bias posizionale

Un secondo fenomeno, del tutto indipendente dal contenuto delle frasi, riguarda la posizione della risposta. Sebbene l'intruso reale sia distribuito in modo abbastanza uniforme sulle quattro posizioni (20%, 29%, 26%, 25% rispettivamente per le posizioni 1–4), le posizioni *predette* dai modelli sono fortemente sbilanciate: la quarta (ultima) posizione viene scelta nel 39.6% dei casi e la prima solo nell'11.5%. Questo sbilanciamento verso l'ultima frase è presente in tutti e cinque i modelli, sebbene con intensità diverse: è estremo in LLaMA 3.1 8B (3.7% sulla prima posizione contro 47.8% sull'ultima) e minimo nei due modelli più accurati, Phi-4 e Qwen 2.5 7B, che sono anche i più equilibrati nella distribuzione delle risposte.

La conseguenza diretta di questo bias è riportata nella Tabella 7: l'accuratezza dipende in misura marcata dalla posizione in cui l'intruso si trova realmente. Quando l'intruso è in prima posizione l'accuratezza crolla a 0.27, appena sopra il livello del caso (0.25), mentre quando è in ultima posizione sale a 0.65. In altre parole, i modelli tendono a individuare l'intruso non tanto perché ne riconoscono la diversità semantica, quanto perché è collocato nella posizione che sono comunque predisposti a scegliere.

Tabella 7: Accuratezza (su tutti i modelli e le quattro strategie base) in funzione della posizione in cui si trova realmente l'intruso.

Posizione intruso	**1**	**2**	**3**	**4**
Accuratezza	0.27	0.48	0.48	0.65

La matrice di confusione fra posizione reale e posizione predetta (Tabella 8) conferma il quadro: la diagonale (risposte corrette) è nettamente più marcata per la quarta posizione (69.1%), mentre per la prima posizione la risposta errata più frequente è proprio la quarta (42.7%), scelta addirittura più spesso di quella corretta (28.6%). Complessivamente, quando i modelli sbagliano, nel 45.5% dei casi indicano l'ultima frase.

Tabella 8: Matrice di confusione fra la posizione reale dell'intruso (righe) e la posizione predetta (colonne), in percentuale di riga, sulle sole risposte interpretabili.

Gold \ Predetto	**1**	**2**	**3**	**4**
Posizione 1	28.6	17.2	11.4	42.7
Posizione 2	7.7	49.8	12.9	29.6
Posizione 3	6.0	22.9	50.5	20.5
Posizione 4	8.1	12.2	10.7	69.1

7.3 Un caso anomalo: rifiuto sistematico di LLaMA 3.1 8B sulla strategia Few-Shot

Durante l'analisi dei risultati è emerso un fenomeno inatteso e specifico, riconducibile a un comportamento di *rifiuto* del modello.

Nella combinazione LLaMA 3.1 8B + strategia Few-Shot, su 100 quadruple testate il modello ha prodotto una risposta priva di qualunque etichetta interpretabile (né dentro il tag XML, né altrove nel testo) in **74 casi su 100**, contro un'accuratezza complessiva crollata a **0.09** (9 risposte corrette su 100). Per confronto, lo stesso modello, sulle altre tre strategie, non presenta questo fenomeno in misura comparabile; suggerendo che la causa sia specifica alla combinazione fra Role Prompting e la strategia Few-Shot, e non un limite generale del modello sul task.

L'ispezione diretta del testo grezzo restituito dal modello (`risposta_raw`) mostra che, nella quasi totalità dei 74 casi, il modello non tenta nemmeno di risolvere il task, restituendo invece una risposta di rifiuto esplicito. Un esempio :

> *"Non posso aiutarti a riconoscere le sfumature e le ambiguità delle azioni descritte in lingua italiana. Posso fornirti informazioni generali sulle differenze tra 'spingere' e 'premere'?"*

È rilevante osservare che la frase di rifiuto riprende quasi testualmente la formulazione del Role Prompting utilizzato nel prompt (*"riconoscere le sfumature e le ambiguità delle azioni descritte in lingua italiana"*), suggerendo che il modello abbia interpretato la combinazione fra l'identità assegnata (*"esperto linguista"*), la struttura a esempi multipli del Few-Shot e il vincolo di formato XML come una richiesta che attiva un meccanismo di cautela proprio dell'allineamento del modello (*alignment*), piuttosto che come un semplice task di classificazione.

7.4 Esempi rappresentativi di errore

Si riportano di seguito alcuni casi rappresentativi in cui il modello Phi-4 (strategia Zero-Shot) ha fallito nell'identificare correttamente la frase intrusa, utili a illustrare la natura degli errori commessi.

Esempio 1 (quadrupla 1).

1: Il maestro di karate spinge indietro l'allievo
2: Il marinaio spinge la scialuppa di salvataggio fuori dal fianco della nave
3: La ragazza respinge una pila di bollette sul tavolo della cucina verso l'amica
4: L'uomo sdraiato spinge via la ciotola

Intruso atteso: frase 2. Risposta del modello: frase 4.

L'errore è emblematico della difficoltà centrale del task: tutte e quattro le frasi descrivono un'azione di "spingere", per cui il modello non può appoggiarsi ad alcun indizio lessicale e deve discriminare il *tipo* di azione fisica. In questo caso il modello scarta correttamente le frasi più simili tra loro ma sbaglia la scelta finale, indicando la frase 4 invece della 2: un errore su una distinzione semantica sottile.

Esempio 2 (quadrupla 8).

1: L'uomo spinge una sedia a rotelle vuota
2: La bibliotecaria spinge il carrello tra gli scaffali
3: Le marinaie spingono la capsula a forma di proiettile nel cannone gigante
4: Due uomini portano un carretto

Intruso atteso: frase 3. Risposta del modello: frase 4.

Questo secondo esempio illustra il meccanismo opposto e complementare al primo: qui il modello indica la frase 4, l'unica costruita su un verbo lessicalmente diverso ("portano" anziché "spingere"), lasciandosi guidare dall'indizio superficiale. L'intruso atteso è invece la frase 3, che pur condividendo il verbo "spingere" con le prime due descrive un'azione fisica di tipo diverso. Il caso mostra concretamente la tendenza, come detto in precedenza, a privilegiare la differenza lessicale rispetto alla distinzione semantica dell'azione.